Pasos TFG Code

Instalación

1. Clone GitHub Repo
2. Install dependencies and modules
3. Create media list

```
@"
name,domain,type
elpais,elpais.com,national
elmundo,elmundo.es,national
abc,abc.es,national
lavanguardia,lavanguardia.com,national
elconfidencial,elconfidencial.com,digital
eldiario,eldiario.es,digital
20minutos,20minutos.es,digital
publico,publico.es,digital
europapress,europapress.es,wire
elespanol,elespanol.com,digital
larazon,larazon.es,national
elperiodico,elperiodico.com,national
"@ | Set-Content -Encoding UTF8 .\data\media_list.csv
```

4. Crear Lista de Keywords

```
New-Item -ItemType Directory -Force -Path .\data\metadata | Out-Null

@"
salud mental
ansiedad
depresión
estrés
soledad
incertidumbre
fatiga
agotamiento
bienestar emocional
trastorno mental
psicólogo
terapia
suicidio
autolesión
"@ | Set-Content -Encoding UTF8 .\data\metadata\keywords_mh.txt
```

4.1. Lista “COVID contexto” para runs específicos

```
 @"
covid
coronavirus
pandemia
confinamiento
cuarentena
estado de alarma
toque de queda
vacunación
"@ | Set-Content -Encoding UTF8 .\data\metadata\keywords_covid.txt
```

5. Parámetros “España/COVID” guardados en configs/ (para reproducibilidad)

```
@"
country: SP
sources: [gdelt]
time_unit: quarterly
pilot_window: 2020-03-01 to 2020-03-31
full_window: 2019-01-01 to 2023-12-31
media_list: data/media_list.csv
keywords_file: data/metadata/keywords_mh.txt
"@ | Set-Content -Encoding UTF8 .\configs\tfg_phase1_plan.yml
```

Pilot Phase Test

- Pilot mínimo (para validar que todo vaya bien)

```
New-Item -ItemType Directory -Force -Path .\data\raw | Out-Null

python pipeline_manager.py phase1 `
  --keyword "salud mental" ansiedad depresion `
  --from 2020-03-01 `
  --to 2020-03-31 `
  --sources gdelt `
  --country SP `
  --media-list .\data\media_list.csv `
  --output .\data\raw\pilot_spain_mh_2020-03.jsonl
```

Output (07-02-2026)

```
(.venv) PS C:\Users\alvar\Documents\PROGRAMMING\4th Year\TFG> python pipeline_manager.py phase1 `
>>   --keyword "salud mental" ansiedad depresion `
>>   --from 2020-03-01 `
>>   --to 2020-03-31 `
>>   --sources gdelt `
>>   --country SP `
>>   --media-list .\data\media_list.csv `
>>   --output .\data\raw\pilot_spain_mh_2020-03.jsonl
Sobrescribiendo país: PE -> SP
Fuentes seleccionadas: ['gdelt']
País objetivo: SP
Cargando medios desde archivo: data\media_list.csv
  -> Dominios cargados: 12
Iniciando recolección con Daily Chunking (2020-03-01 -> 2020-03-31)...
Guardando resultados incrementalmente en: data\raw\pilot_spain_mh_2020-03.jsonl
  Consultando 2020-03-01...
    -> Ejecutando búsqueda Granular (Día x 12 Medios)...
    -> Sin resultados.
  Consultando 2020-03-02...
    -> Ejecutando búsqueda Granular (Día x 12 Medios)...
    -> Sin resultados.
  Consultando 2020-03-03...
    -> Ejecutando búsqueda Granular (Día x 12 Medios)...
    -> Sin resultados.
  Consultando 2020-03-04...
    -> Ejecutando búsqueda Granular (Día x 12 Medios)...
    -> Sin resultados.
  Consultando 2020-03-05...
    -> Ejecutando búsqueda Granular (Día x 12 Medios)...
    -> Sin resultados.
  Consultando 2020-03-06...
    -> Ejecutando búsqueda Granular (Día x 12 Medios)...
```

```
Proceso completado.
Métricas de Ejecución:
{
  "n_candidates": 3,
  "n_download_ok": 3,
  "n_records_saved": 0,
  "n_skipped_no_text": 3
}
```

A) ¿Funciona GDELT + extracción si NO filtramos por medios?
B) Test con medios “más fáciles” (crea una lista pilot)
C) Activa fuentes híbridas (GDELT + Google + RSS)
- ABC todos 0

Pilot code working: (filtrando solo por covid + 1 dia)

```
(.venv) PS C:\Users\alvar\Documents\PROGRAMMING\4th Year\TFG> python
pipeline_manager.py phase1 `
>>   --keyword "covid" `
>>   --from 2020-03-14 `
>>   --to 2020-03-14 `
>>   --sources gdelt `
>>   --country SP `
>>   --media-list .\data\media_list_pilot.csv `
>>   --output .\data\raw\pilot_spain_mediafiltered_2020-03-14.jsonl

Proceso completado.
Métricas de Ejecución:
{
```

```
  "n_candidates": 159,
  "n_download_ok": 151,
  "n_records_saved": 149,
  "n_skipped_no_text": 10
}
Harvest completado: 149 registros almacenados en
data\raw\pilot_spain_mediafiltered_2020-03-14.jsonl. Se omitieron 10
artículos vacíos/irrelevantes.
```

Pilot Covid (3 keywords + 1 semana)

Fase A — Pilot estable (1 semana, pocos medios)

- Objetivo: confirmar que para tu query broad se guardan registros con texto, y que n_records_saved es alto.

```
python pipeline_manager.py phase1 `
  --keyword covid coronavirus pandemia `
  --from 2020-03-09 `
  --to 2020-03-15 `
  --sources gdelt `
  --country SP `
  --media-list .\data\media_list_pilot.csv `
  --output .\data\raw\spain_covid_broad_2020-03-09_2020-03-15.jsonl
```

- Ejecutando 1 semana, tarda mucho. CAMBIAR periodico 20 minutos a false (active) y probar si mejora el tiempo para otra semana. Periodico 20 mins da muchos waybacks.

```
Proceso completado.
Métricas de Ejecución:
{
  "n_candidates": 1529,
  "n_download_ok": 1280,
  "n_records_saved": 1271,
  "n_skipped_no_text": 258
}
Harvest completado: 1271 registros almacenados en
data\raw\spain_covid_broad_2020-03-09_2020-03-15.jsonl. Se omitieron 258
artículos vacíos/irrelevantes.
```

Fase B — Mes completo, todavía con media list pilot

- Objetivo: un mes entero (p.ej. marzo 2020) pero en bloques de semana para evitar rate limits.

- Ya tenemos 9-15
- 01-08
- 16-22
- 23-31

  Para el de 16-31 juntado ejecutar por la noche, pongo periodico 20 mins como active=false

Fase C — Filtrado MH sobre el JSONL (ya local)

- Objetivo: producir un *_mh.jsonl con solo artículos relacionados con salud mental.

- Fase B completada, mes de marzo entero filtrando por covid, coronavirus, pandemia. Tenemos un total de 61,080
- 01-08 total de 6,805
- 09-15 total de 28,454
- 16-31 25,821

Script filtrar mental health terms:

```
@'
import json
import re
import unicodedata
from pathlib import Path

def norm(s: str) -> str:
    s = s.lower()
    s = "".join(ch for ch in unicodedata.normalize("NFD", s) if
unicodedata.category(ch) != "Mn")
    return s

def load_keywords(path: Path) -> list[str]:
    kws = []
    for line in path.read_text(encoding="utf-8").splitlines():
        line = line.strip()
        if not line or line.startswith("#"):
            continue
        kws.append(line)
    return kws

def compile_patterns(kws: list[str]) -> list[tuple[str, re.Pattern]]:
    out = []
    for kw in kws:
        k = norm(kw)
        if " " in k:
            pat = re.compile(re.escape(k))
```

```
        else:
            pat = re.compile(rf"\b{re.escape(k)}\b")
        out.append((kw, pat))
    return out

def get_text(rec: dict) -> str:
    parts = []
    for f in ("title", "description", "text", "content"):
        v = rec.get(f)
        if isinstance(v, str) and v.strip():
            parts.append(v.strip())
    return "\n".join(parts)

def filter_file(in_path: Path, out_path: Path, patterns):
    n_in = 0
    n_out = 0

    with in_path.open("r", encoding="utf-8") as fin, out_path.open("w",
encoding="utf-8") as fout:
        for line in fin:
            line = line.strip()
            if not line:
                continue
            n_in += 1
            rec = json.loads(line)

            txt = norm(get_text(rec))
            hits = [kw for kw, pat in patterns if pat.search(txt)]
            if hits:
                rec["_mh_matches"] = hits
                fout.write(json.dumps(rec, ensure_ascii=False) + "\n")
                n_out += 1

    return n_in, n_out

def main():
    kw_path = Path(r"data/metadata/keywords_mh.txt")
    in_dir = Path(r"data/raw")
    out_dir = Path(r"data/interim")
    out_dir.mkdir(parents=True, exist_ok=True)

    patterns = compile_patterns(load_keywords(kw_path))

    files = sorted(in_dir.glob("spain_covid_broad_2020-03-*.jsonl"))
    if not files:
        raise SystemExit("No input files found in data/raw (expected
```

```
spain_covid_broad_2020-03-*.jsonl)")

    total_in = 0
    total_out = 0

    for fp in files:
        out_fp = out_dir / fp.name.replace("spain_covid_broad",
"spain_covid_MH")
        n_in, n_out = filter_file(fp, out_fp, patterns)
        total_in += n_in
        total_out += n_out
        print(f"{fp.name}: in={n_in}  mh={n_out}  -> {out_fp.name}")

    print(f"\nTOTAL: in={total_in}  mh={total_out}
({(total_out/total_in*100 if total_in else 0):.2f}%)")

if __name__ == "__main__":
    main()
'@ | Set-Content -Encoding UTF8 .\scripts\filter_mh.py
```

Ejecutar script:

```
python .\scripts\filter_mh.py
```

Creamos Keywords Socioeconomic

- Temas como paro, desempleo, pobreza, etc. Se puede ver a futuro si se ve un aumento en estos temas y luego relacionados con salud mental.

Contamos BIEN LOS FILES, NO TENEMOS 60K NOTICIAS, SON LINEAS.

- Creamos script file filter_mh_csv.py
- Creamos strict mh terms para reducir ruido y noticias no relevantes.

Resultado Fase C (marzo 2020, media_list_pilot)

- 01–08: 4 / 310 → 1.29%
- 09–15: 35 / 1271 → 2.75%
- 16–31: 59 / 1210 → 4.88%
- Total marzo: 98 / 2791 → 3.51%

Esto además cuenta una historia plausible: sube conforme avanza marzo (confinamiento / estado de alarma y efectos).

Unir Marzo Completo

```
Get-ChildItem .\data\interim\spain_covid_MH_strict_covidOK_2020-03-*.csv
```

```
|
  Sort-Object Name |
  ForEach-Object { Import-Csv $_.FullName } |
  Export-Csv
.\data\interim\spain_covid_MH_strict_covidOK_2020-03_ALL.csv
-NoTypeInformation -Encoding UTF8
```

- Luego se ha renombrado este archivo para mantener consistencia en cuanto a nombres.

Fase D — Escalar medios (lista completa)
Cuando verificado que:

- el pipeline guarda bien (pocos no_text)
- los dominios no dan demasiados 404
- el filtrado MH produce un tamaño razonable

```
Total marzo: 98 / 2791 → 3.51%
```

Media Onboarding Test

- Objetivo es comprobar media sources, dan problemas?, funcionan bien? Una vez tengamo slista funcional de media, pasamos a escalada completa.

Una vez media test funcional, organizamos carpetas y archivos u preparamos todo para escalar.

data/

- **raw/**
  - **harvest/** → *salidas de phase1 "covid broad" (meses completos)*
  - **diagnostics/** → *tests de 1 día / pruebas de medios (`diag_*`)*
- **interim/**
  - **filters/**
    - **mh_v1/** → tu filtro antiguo (`spain_covid_MH_...`)
    - **mh_v2_strict_covidOK/** → tu filtro bueno (`spain_covid_MH_strict_covidOK_...`)
  - **diagnostics/** → outputs filtrados de tests (ej. `diag_*_MH_...`)
  - **logs/** → `_bad_json_lines.log`
- **metadata/**
  - **keywords/** → `keywords_*.txt`
  - **media_lists/** → `media_list_*.csv`
  - **anchors/** → `dimensiones_ancla.json`

runs/ (opcional pero muy útil): notas de cada ejecución (comandos + qué media list usaste + periodo)

ACLARACIÓN FILTER MH CSV SCRIPTS

- filter_mh.py → no funcionó, leíamos mal los datos (no leyéndolos como csv structure).
- filter_mh_csv.py → primer script, usado para marzo pilot sin opción de elegir mes. Aparte, muy permisivo en cuanto a keywords (metía mucho ruido, no tanto related mh) muchos falsos positivos. Aqui creamos `keywords_mh_strict.txt`
- filter_mh_csv_v2.py → usado tras la reorganización no opcion elegir mes.
- filter_mh_csv_v2_cli.py → extension de la version anterior pero ahora con opcion de elegir mes `--month 2020-04` o año `--year YYYY`

Phase 1:

Una vez pilot validado y funcional avanzamos al desarrollo e implementación completa.

Producción Mensual

Para fase 1 mes a mes, marzo ya sacado

Marzo 2020

```
01-08: 4 / 310 → 1.29%
09-15: 35 / 1271 → 2.75%
16-31: 59 / 1210 → 4.88%
Total marzo: 98 / 2791 → 3.51%
```

Abril 2020

```
python pipeline_manager.py phase1 `
  --keyword covid coronavirus pandemia `
  --from 2020-04-01 `
  --to 2020-04-30 `
  --sources gdelt `
  --country SP `
  --media-list .\data\metadata\media_lists\media_list_pilot_core.csv `
  --output
.\data\raw\harvest\spain_covid_broad_2020-04-01_2020-04-30.csv
```

Output

```
Proceso completado.
Métricas de Ejecución:
```

```
{
  "n_candidates": 8520,
  "n_download_ok": 8502,
  "n_records_saved": 8411,
  "n_skipped_no_text": 109
}
Harvest completado: 8411 registros almacenados en
data\raw\harvest\spain_covid_broad_2020-04-01_2020-04-30.csv. Se
omitieron 109 artículos vacíos/irrelevantes.
```

Output Filter MH
Despues de aplicar python script ‘filter_mh_csv_v2_cli.py’

```
TOTAL: in=8411  out=463  (5.50%)
```

Mayo 2020

```
python pipeline_manager.py phase1 `
  --keyword covid coronavirus pandemia `
  --from 2020-05-01 `
  --to 2020-05-31 `
  --sources gdelt `
  --country SP `
  --media-list .\data\metadata\media_lists\media_list_pilot_core.csv `
  --output
.\data\raw\harvest\spain_covid_broad_2020-05-01_2020-05-31.csv
```

Output

```
Proceso completado.
Métricas de Ejecución:
{
  "n_candidates": 6017,
  "n_download_ok": 6012,
  "n_records_saved": 5935,
  "n_skipped_no_text": 82
}
Harvest completado: 5935 registros almacenados en
data\raw\harvest\spain_covid_broad_2020-05-01_2020-05-31.csv. Se
omitieron 82 artículos vacíos/irrelevantes.
```

Despues de aplicar python script ‘filter_mh_csv_v2_cli.py’

```
python .\scripts\filter_mh_csv_v2_cli.py --month 2020-05
```

Output Filter MH

```
TOTAL: in=5935  out=261  (4.40%)
```

Junio 2020

```
python pipeline_manager.py phase1 `
  --keyword covid coronavirus pandemia `
  --from 2020-06-01 `
  --to 2020-06-30 `
  --sources gdelt `
  --country SP `
  --media-list .\data\metadata\media_lists\media_list_pilot_core.csv `
  --output
.\data\raw\harvest\spain_covid_broad_2020-06-01_2020-06-30.csv
```

Output

```
Proceso completado.
Métricas de Ejecución:
{
  "n_candidates": 4164,
  "n_download_ok": 4161,
  "n_records_saved": 4102,
  "n_skipped_no_text": 62
}
Harvest completado: 4102 registros almacenados en
data\raw\harvest\spain_covid_broad_2020-06-01_2020-06-30.csv. Se
omitieron 62 artículos vacíos/irrelevantes.
```

Despues de aplicar python script ‘filter_mh_csv_v2_cli.py’

```
python .\scripts\filter_mh_csv_v2_cli.py --month 2020-06
```

Output Filter MH

```
TOTAL: in=4102  out=169  (4.12%)
```

Julio 2020

```
python pipeline_manager.py phase1 `
  --keyword covid coronavirus pandemia `
  --from 2020-07-01 `
  --to 2020-07-31 `
  --sources gdelt `
  --country SP `
  --media-list .\data\metadata\media_lists\media_list_pilot_core.csv `
  --output
.\data\raw\harvest\spain_covid_broad_2020-07-01_2020-07-31.csv
```

Output
Para este ns xq no me dio resumen final, pero he sacado esto.

```
records= 3802 unique_urls= 3766 dups= 36
```

Despues de aplicar python script ‘filter_mh_csv_v2_cli.py’

```
python .\scripts\filter_mh_csv_v2_cli.py --month 2020-07
```

Output Filter MH

```
TOTAL: in=3802  out=131  (3.45%)
```

Agosto 2020

```
python pipeline_manager.py phase1 `
  --keyword "covid" "coronavirus" "pandemia" `
  --from 2020-08-01 `
  --to 2020-08-31 `
  --sources gdelt `
  --country SP `
  --media-list .\data\metadata\media_lists\media_list_pilot_core.csv `
  --output
.\data\raw\harvest\spain_covid_broad_2020-08-01_2020-08-31.csv
```

Output

```
Proceso completado.
Métricas de Ejecución:
{
  "n_candidates": 3836,
```

```
  "n_download_ok": 3817,
  "n_records_saved": 3735,
  "n_skipped_no_text": 101
}
Harvest completado: 3735 registros almacenados en
data\raw\harvest\spain_covid_broad_2020-08-01_2020-08-31.csv. Se
omitieron 101 artículos vacíos/irrelevantes.
Exception ignored in: <function ResourceTracker.__del__ at
0x0000018740E91BC0>
```

Despues de aplicar python script ‘filter_mh_csv_v2_cli.py’

```
python .\scripts\filter_mh_csv_v2_cli.py --month 2020-08
```

Output Filter MH

```
TOTAL: in=3735  out=141  (3.78%)
```

Septiembre 2020

```
python pipeline_manager.py phase1 `
  --keyword "covid" "coronavirus" "pandemia" `
  --from 2020-09-01 `
  --to 2020-09-30 `
  --sources gdelt `
  --country SP `
  --media-list .\data\metadata\media_lists\media_list_pilot_core.csv `
  --output
.\data\raw\harvest\spain_covid_broad_2020-09-01_2020-09-30.csv
```

Output

```
Proceso completado.
Métricas de Ejecución:
{
  "n_candidates": 3919,
  "n_download_ok": 3905,
  "n_records_saved": 3841,
  "n_skipped_no_text": 78
}
Harvest completado: 3841 registros almacenados en
data\raw\harvest\spain_covid_broad_2020-09-01_2020-09-30.csv. Se
```

```
omitieron 78 artículos vacíos/irrelevantes.
```

Despues de aplicar python script ‘filter_mh_csv_v2_cli.py’

```
python .\scripts\filter_mh_csv_v2_cli.py --month 2020-09
```

Output Filter MH

```
TOTAL: in=3841  out=148  (3.85%)
```

Octubre 2020

```
python pipeline_manager.py phase1 `
  --keyword "covid" "coronavirus" "pandemia" `
  --from 2020-10-01 `
  --to 2020-10-31 `
  --sources gdelt `
  --country SP `
  --media-list .\data\metadata\media_lists\media_list_pilot_core.csv `
  --output
.\data\raw\harvest\spain_covid_broad_2020-10-01_2020-10-31.csv
```

Output

```
Proceso completado.
Métricas de Ejecución:
{
  "n_candidates": 2311,
  "n_download_ok": 2296,
  "n_records_saved": 2263,
  "n_skipped_no_text": 48
}
Harvest completado: 2263 registros almacenados en
data\raw\harvest\spain_covid_broad_2020-10-01_2020-10-31.csv. Se
omitieron 48 artículos vacíos/irrelevantes.
```

Despues de aplicar python script ‘filter_mh_csv_v2_cli.py’

```
python .\scripts\filter_mh_csv_v2_cli.py --month 2020-10
```

Output Filter MH

```
TOTAL: in=2263  out=73  (3.23%)
```

Noviembre 2020

```
python pipeline_manager.py phase1 `
  --keyword "covid" "coronavirus" "pandemia" `
  --from 2020-11-01 `
  --to 2020-11-30 `
  --sources gdelt `
  --country SP `
  --media-list .\data\metadata\media_lists\media_list_pilot_core.csv `
  --output
.\data\raw\harvest\spain_covid_broad_2020-11-01_2020-11-30.csv
```

Output

```
Proceso completado.
Métricas de Ejecución:
{
  "n_candidates": 3008,
  "n_download_ok": 2981,
  "n_records_saved": 2922,
  "n_skipped_no_text": 86
}
Harvest completado: 2922 registros almacenados en
data\raw\harvest\spain_covid_broad_2020-11-01_2020-11-30.csv. Se
omitieron 86 artículos vacíos/irrelevantes.
```

Despues de aplicar python script ‘filter_mh_csv_v2_cli.py’

```
python .\scripts\filter_mh_csv_v2_cli.py --month 2020-11
```

Output Filter MH

```
TOTAL: in=2922  out=115  (3.94%)
```

Diciembre 2020

```
python pipeline_manager.py phase1 `
  --keyword "covid" "coronavirus" "pandemia" `
```

```
  --from 2020-12-01 `
  --to 2020-12-31 `
  --sources gdelt `
  --country SP `
  --media-list .\data\metadata\media_lists\media_list_pilot_core.csv `
  --output
.\data\raw\harvest\spain_covid_broad_2020-12-01_2020-12-31.csv
```

Output

```
Proceso completado.
Métricas de Ejecución:
{
  "n_candidates": 3583,
  "n_download_ok": 3573,
  "n_records_saved": 3506,
  "n_skipped_no_text": 77
}
```

Despues de aplicar python script ‘filter_mh_csv_v2_cli.py’

```
python .\scripts\filter_mh_csv_v2_cli.py --month 2020-12
```

Output Filter MH

```
TOTAL: in=3506  out=126  (3.59%)
```

Resumen AÑO 2020

Mes	Media list	LV	n_candidates	n_download_ok	n_records_saved	n_skipped_no_text	MH_out	MH_%
2020-03 (pilot)	media_list_pilot	ON	—	—	2791	—	98	3.51%
2020-04	media_list_pilot_core	ON	8520	8502	8411	109	463	5.50%
2020-05	media_list_pilot_core	OFF	6017	6012	5935	82	261	4.40%
2020-06	media_list_pilot_core	OFF	4164	4161	4102	62	169	4.12%

2020-07	media_list_pilot_core	OFF	—	—	3802	—	131	3.45%
2020-08	media_list_pilot_core	ON (test)	3836	3817	3735	101	141	3.78%
2020-09	media_list_pilot_core	ON	3919	3905	3841	78	148	3.85%
2020-10	media_list_pilot_core	ON	2311	2296	2263	48	73	3.23%
2020-11	media_list_pilot_core	ON	3008	2981	2922	86	115	3.94%
2020-12	media_list_pilot_core	ON	3583	3573	3506	77	126	3.59%

Enero 2021

```
Proceso completado.
Métricas de Ejecución:
{
  "n_candidates": 4701,
  "n_download_ok": 4620,
  "n_records_saved": 4519,
  "n_skipped_no_text": 182
}
Harvest completado: 4519 registros almacenados en
data\raw\harvest\spain_covid_broad_2021-01-01_2021-01-31.csv. Se
omitieron 182 artículos vacíos/irrelevantes.
```

```
TOTAL: in=4519  out=149  (3.30%)
```

Febrero 2021

```
Proceso completado.
Métricas de Ejecución:
{
  "n_candidates": 3524,
  "n_download_ok": 3515,
  "n_records_saved": 3414,
  "n_skipped_no_text": 110
}
Harvest completado: 3414 registros almacenados en
data\raw\harvest\spain_covid_broad_2021-02-01_2021-02-28.csv. Se
omitieron 110 artículos vacíos/irrelevantes.
```

```
TOTAL: in=3414  out=119  (3.49%)
```

Marzo 2021

```
Proceso completado.
Métricas de Ejecución:
{
  "n_candidates": 4240,
  "n_download_ok": 4232,
  "n_records_saved": 4132,
  "n_skipped_no_text": 108
}
Harvest completado: 4132 registros almacenados en
data\raw\harvest\spain_covid_broad_2021-03-01_2021-03-31.csv. Se
omitieron 108 artículos vacíos/irrelevantes.
```

```
TOTAL: in=4132  out=164  (3.97%)
```

Juntar Yearly Data / Quarterly

```

```

PENSAR SI QUEREMOS INCLUIR UN EXTENDED FILTER (fase C) sobre corpus entero relacionado con factores socioeconomicos, psychological. (ERTE, desempleo, confinamiento, estado de alarma, …..)

A

Fase 2 NLP

Descarga de Modelos

```
# (opcional pero muy recomendable) cache de HF dentro del proyecto
$env:HF_HOME = "$PWD\models\hf_home"
$env:TRANSFORMERS_CACHE = "$env:HF_HOME\transformers"
$env:HF_DATASETS_CACHE = "$env:HF_HOME\datasets"
```

```
python pipeline_manager.py phase2 download-models `
  --models "dccuchile/bert-base-spanish-wwm-uncased"
"PlanTL-GOB-ES/roberta-large-bne"
```

HF_READ_TOKEN = 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

HF_TOKEN = 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

IMPORTANTE MODELOS

```
python pipeline_manager.py phase2 download-models `
  --models "dccuchile/bert-base-spanish-wwm-uncased"
```

El siguiente modelo esta deprecated, y no funciona pasamos a usar solo el de arriba.

- `PlanTL-GOB-ES/roberta-large-bne`

Modelos

Creamos script merge_monthly.py

- Este script se usara para unir todos los monthly data a un aggregated data
- Este agg data lo usaremos para dapt y resto de project

Para Fase 2

- Corpus para tu TFG (analisis): covidMHstrict_covidOK ✅
- DAPT: sobre corpus grande (pre-training sobre covid related)
- Embeddings/occurrences: de términos MH, no de “covid” ✅

DAPT

```
python pipeline_manager.py phase2 dapt `
  --data ".\data\raw\harvest\_merged\spain_covid_broad_ALL.csv" `
  --output ".\models\beto_dapt_spain_covid_2020-03_2021-03" `
  --model "dccuchile/bert-base-spanish-wwm-uncased" `
  --epochs 3
```

DAPT → al hacer en dataset entero

```
KeyboardInterrupt
0%|          | 458/1109940 [16:03<648:21:32,  2.10s/it]
```

DUE to computational costs, time effectivenes. Vamos a probar a hacer dapt en covid mh strict. Y a reducir a epochs 1. Reducimos dataset volumen y n of epochs.

Vamos a probar con dapt en covid strict, si se queda corto se puede hacer un subset de covid broad.

Opción 1 (recomendada por tiempo): DAPT en MH-strict (covidMHstrict)

- Dataset mucho más pequeño (**~2156 artículos**).
- Te corre en un tiempo razonable (horas, no semanas).
- Es defendible porque tu tarea final es *mental health during COVID*.

Opción 2 (mejor "académicamente" pero aún viable): DAPT en un SUBSET del broad

- DAPT "de verdad" suele necesitar bastante texto; MH-strict puede quedarse corto.
- Solución: haces DAPT con **un muestreo** (p.ej. 5k–10k artículos del broad) para capturar vocabulario COVID/medidas, y luego embeddings sobre MH-strict.
- Esto es defendible y no te obliga a re-harvestear nada.

Con CPU, **NO hagas DAPT en el broad completo.**

Opcion A (la que estoy probando)

```
python pipeline_manager.py phase2 dapt `
  --data
".\data\interim\datasets\spain_covidMHstrict_2020-03_2021-03_ALL.csv" `
  --output ".\models\beto_dapt_spain_MHstrict_2020-03_2021-03_e1" `
  --model "dccuchile/bert-base-spanish-wwm-uncased" `
  --epochs 1
```

Opcion B - Sample

```
python -c "import pandas as pd;
fp=r'data/raw/harvest/_merged/spain_covid_broad_ALL.csv';
df=pd.read_csv(fp, encoding='utf-8-sig'); df=df[df['plain_text'].notna()
& (df['plain_text'].str.len()>200)]; df=df.sample(n=5000,
random_state=42);
out=r'data/raw/harvest/_merged/spain_covid_broad_sample5000.csv';
df.to_csv(out, index=False, encoding='utf-8-sig'); print('OK ->', out,
'rows=', len(df))"
```

```
python pipeline_manager.py phase2 dapt `
  --data ".\data\raw\harvest\_merged\spain_covid_broad_sample5000.csv" `
  --output ".\models\beto_dapt_spain_covid_sample5000_e1" `
  --model "dccuchile/bert-base-spanish-wwm-uncased" `
  --epochs 1
```

Estoy probando opcion A, con el dataset entero. Lo dejo toda la noche ejecutando pero me dice que tarda aprox 10h.

```
{'train_runtime': 31740.7579, 'train_samples_per_second': 2.265,
'train_steps_per_second': 0.566, 'train_loss': 2.367525761964657,
'epoch': 1.0}
100%|
|
17970/17970 [8:49:00<00:00,  1.77s/it]
INFO:src.nlp.dapt:Saving adapted model to
.\models\beto_dapt_spain_MHstrict_2020-03_2021-03_e1
***** train metrics *****
  epoch                    =        1.0
  total_flos               =  4404985GF
  train_loss               =     2.3675
  train_runtime            = 8:49:00.75
  train_samples_per_second =      2.265
  train_steps_per_second   =      0.566
INFO:src.nlp.dapt:DAPT complete.
(.venv) PS C:\Users\alvar\Documents\PROGRAMMING\4th Year\TFG>
```

DAPT Listo pasamos a embeddings

EMBEDDINGS

a

```
python pipeline_manager.py phase2 extract `
  --data_dir ".\data\interim\filters\mh_v2_strict_covidOK" `
  --output
".\data\interim\embeddings\spain_covidMHstrict_occurrences_2020-03_2021-
03.parquet" `
  --model "dccuchile/bert-base-spanish-wwm-uncased" `
  --dapt_model ".\models\beto_dapt_spain_MHstrict_2020-03_2021-03_e1" `
  --keywords "salud mental" "ansiedad" "depresion" "depresión" "estres"
"estrés" "suicidio" "soledad" "miedo" "psicosis" "psicologo" "psicólogo"
"terapia" "autolesion" "autolesión" "trastorno mental" "psiquiatria"
"psiquiatría"
```

TRABAJAR EN BRANCH CON ANTIGRAVITY NO push main brand.

EMbeddings listo, creado parquet file, 1.14gb

Pasamos a fase 3

Fase 3

Creamos dimensiones ancla

Ejecutamos con windows de 3

```
python pipeline_manager.py phase3 `
  --input
".\data\interim\embeddings\spain_covidMHstrict_occurrences_2020-03_2021-
03.parquet" `
  --output-dir ".\results\phase3\mh_strict_covidOK_2020-03_2021-03_w3" `
  --window-months 3 `
  --dapt-model ".\models\beto_dapt_spain_MHstrict_2020-03_2021-03_e1" `
  --baseline-model "dccuchile/bert-base-spanish-wwm-uncased" `
  --iters 200 `
  --anchors
".\data\metadata\anchors\dimensiones_ancla_mh_es_covid_FSA.json"
```

Esta tardando mucho para 1 ventana ~4h y contando. Si vemos que tarda demasiado, bajar --iters a 50 o 25. Debería acelerar el proceso.

Time check: empezo a las ~13:15

- 16:35 sigue procesando widow 1/11 2020-03 to 2020-05.
  6 subspaces (baseline last 4 concat corrected, last4 concat raw, penultimate corrected penultimate raw, y dapt penultimate corrected y penultimate raw)
  4 anchors (baseline last4, penultimate y dapt last4 y penultimate)
- 17:00 subspaces = 7 → dapt last 4 concat raw
- 1730 igual
- 1751 window 2
- 1754 subspace baseline penultimate raw
- 1800 bsl penultimate raw
- 1901 bsl last4 concat raw
- 0046 window 5 → 6/8

HAY QUE HACER EDA sobre dataset IMBECIL, antes de correr PHASE 3

EDA

- Here

```
# 2.2 A) Identificación
    req_cols_a = ['occurrence_id', 'run_id', 'model_id', 'model_variant',
'layer_strategy', 'pooling_strategy']
```

occurrence_id, run_id, model_baseline, model_dapt,

```
# 2.2 B) Información temporal
    req_cols_b = ['published_at', 'year', 'month', 'year_month']
    missing_b = [c for c in req_cols_b if c not in df.columns]
```

published_at, year, month, year_month

```
# 2.2 C) Fuente
    req_cols_c = ['newspaper', 'source_api', 'url']
    missing_c = [c for c in req_cols_c if c not in df.columns]
```

newspaper, source_api, url

```
# 2.2 D) Lingüística (CRITICO)
    req_cols_d = ['keyword_canonical', 'keyword_matched', 'char_start',
'char_end', 'token_start', 'token_end']
    missing_d = [c for c in req_cols_d if c not in df.columns]
```

keyword, keyword_found, char_start, char_end, token_start, token_end

```
# 2.2 E) Contexto
    req_cols_e = ['context_sentence'] # context_window is optional
    missing_e = [c for c in req_cols_e if c not in df.columns]
```

context_sentence

```
# 2.2 F) Embeddings
    req_cols_f = ['embedding_contextual_last4',
'embedding_contextual_penultimate']
```

```
    missing_f = [c for c in req_cols_f if c not in df.columns]
```

embedding_baseline_last4_concat,
embedding_baseline_penultimate,
embedding_dapt_last4_concat,
embedding_dapt_penultimate

Creamos este archivo:

- 02_eda_embeddings_integrity.ipynb
- Esta en notebooks folder

Ahora ejecutar script Phase 2 EDA ipynb

Mas o menos ya esta clean el dataset, en arrays y sin nulls (no habia)

Volvemos a ejecutar fase 3

```
python pipeline_manager.py phase3 `
  --input
".\data\interim\embeddings\spain_covidMHstrict_occurrences_2020-03_2021-
03_CLEANED.parquet" `
  --output-dir
".\results\phase3\mh_strict_covidOK_2020-03_2021-03_w3_FINAL_CLEANED" `
  --window-months 3 `
  --dapt-model ".\models\beto_dapt_spain_MHstrict_2020-03_2021-03_e1" `
  --baseline-model "dccuchile/bert-base-spanish-wwm-uncased" `
  --iters 50 `
  --anchors
".\data\metadata\anchors\dimensiones_ancla_mh_es_covid_FSA.json"
```

ERROR primero de todo neesita ser csv

Segundo da error porque anchor keyword no match found sentence, problema con tildes, igual que antes.

```
RuntimeError: FAIL: Keyword 'psicólogo' not found in sentence: 'El psicólogo recomienda pautas para manejar la ansiedad durante la pandemia.'
(.venv) PS C:\Users\alvar\Documents\PROGRAMMING\4th Year\TFG> python pipeline_manager.py phase3 `
>>   --input ".\data\interim\embeddings\spain_covidMHstrict_occurrences_2020-03_2021-03_CLEANED.csv" `
>>   --output-dir ".\results\phase3\mh_strict_covidOK_2020-03_2021-03_w3_FINAL_CLEANED" `
>>   --window-months 3 `
>>   --dapt-model ".\models\beto_dapt_spain_MHstrict_2020-03_2021-03_e1" `
>>   --baseline-model "dccuchile/bert-base-spanish-wwm-uncased" `
>>   --iters 50 `
>>   --anchors ".\data\metadata\anchors\dimensiones_ancla_mh_es_covid_FSA_ascii.json"
                                                                                    Spaces: 4
```

Nos da error en window 5, hacemos cambio en linea 219.

Seguimos con error en window 7 → Creamos script inspect window 7 .py

Fase 3 Analysis

Hacemos analysis

Creamos file para analizar y comparar techniques (layer strategy, corrected vs raw, model
- Conclusion = DAPT + PENULTIMATE + CORRECTED

02_eda_embeddings_integrity.ipynb
- Control de calidad
- Data exploration
- Plot de ocurrencias mensuales, plot con principales hitos de la pandemia.
- Plot de keywords, miedo y ansiedad, protagonistas frecuentes.
- Histograma de similitud dapt vs baseline

phase3_results.csv
- Resultados del extract, hacemos un parquet sobre este con code python

phase3_complete_analysis.ipynb
- Generador de evidencias
- Centroid plot
- Trayectoria semantica scatter plot 2d, mapa visual de como se mueve el concepto
- Drift y estabilidad, para decir cuando cambio mas el discurso (picos de inestabilidad)

Raw vs. Corrected (La Anisotropía)

¿Qué es la corrección?
Imagina que todos los vectores del idioma español apuntan un poco hacia el "Norte". Si mides la distancia entre dos palabras, te parecerá que están cerca porque ambas van al Norte. La "Corrección de Anisotropía" elimina ese "Norte magnético" común para ver la dirección real.

Estrategia para el Deliverable:

Menciona la técnica: En la sección de Algorithms, escribe un párrafo sobre "Dual Anisotropy Correction". Di que es necesaria para evitar falsos positivos en la similitud coseno.

Comparativa Visual:
- Genera los plots con Corrected (ya los tienes en el CSV).
- Tu argumento: "Aunque aplicamos la corrección rigurosa (Corrected), observamos que las tendencias se mantienen estables respecto a los datos crudos (Raw), lo que valida la robustez de nuestros hallazgos. Para la visualización final, presentamos los datos corregidos para mayor pureza matemática".